# Agentic Engineering

*Christian Budde* @MeKo-Christian

Von einfachen Anfragen zu agentischem Arbeiten

## 💬 Einzelner Prompt

ChatGPT, Claude.ai, Gemini, ...

```
Mensch: Prompt

LLM:    Antwort
          ↓
     Mensch liest,
    kopiert, prüft,
     führt aus, ...
```

- **Eine** Frage, **eine** Antwort
- LLM sieht nur Text — **handelt nicht**
- Jeder Schritt: Mensch ist Ausführer
- Kontext endet mit der Antwort

→ **Prompt Engineering** = Kunst, den richtigen Prompt zu formulieren

# 🤖 Agent

[Claude Code, Codex, Gemini CLI, Cursor, GitHub Copilot Agent, ...]

```
Mensch → Ziel(prompt)
           ↓
      Agent plant
           ↓
    Tool aufrufen  ← Shell / Dateien
           ↓             / Web / Tests
    Ergebnis lesen
           ↓
    weiter iterieren
           ↓
      Ziel erreicht?
```

- **Ein** Ziel, **viele** autonome Schritte
- LLM **handelt**: schreibt, führt aus, liest
- Mensch gibt Richtung — Agent arbeitet
- Kontext bleibt über den ganzen Prozess erhalten

→ **Kontext Engineering** = Kunst, den Agenten mit dem richtigen Kontext zu versorgen

# 🎲 Vibe Coding

Karpathy, Feb 2025

*„Fully give in to the vibes, embrace exponentials,*
forget that the code even exists.“

- Code generieren → **Accept All** → hoffen
- Kein Review, keine Tests, kein Verständnis
- Optimiert für: schnelle Wegwerfprojekte
- Verantwortung: keine

Funktioniert für Prototypen und Wegwerfcode —
**nicht** für Software, die jemand warten, deployen
oder auf die sich jemand verlassen muss.

## ⚙️ Agentic Engineering

Willison, 2025

*„Seasoned professionals accelerate their work — proudly accountable for the software they ship.“*

- Agent = **LLM + Tools + Loop** → Ziel erreichen
- Code wird ausgeführt, getestet, iteriert
- Expertise wird verstärkt, nicht ersetzt
- Verantwortung: bleibt beim Entwickler

**Die Teilkosten fürs Tippen sinken — die Kosten für *guten* Code nicht.**

Korrektheit, Tests, Sicherheit, Wartbarkeit: weiterhin Aufgabe des Entwicklers.

# Das Ökosystem: Coding Agents & CLIs

## Terminal / CLI

- **Claude Code** — Sonnet 4.6, Opus 4.6
- **OpenAI Codex CLI** — GPT-5.2, GPT-5.3-Codex
- **Gemini CLI** — Gemini 3.1 Pro (1M Tokens)

## IDE-Erweiterungen

- **GitHub Copilot Agent** — GPT-5, Claude Sonnet
- **Cline / Roo Code** — VS Code, beliebige Modelle
- **Continue** — open source, lokal oder cloud

## AI-first IDEs

- **Cursor** — Sonnet, GPT-4.1, eigene Modelle
- **Windsurf** (Codeium) — SWE-1, Claude, GPT
- **VS Code + Copilot** — Edits-Modus, Agent-Modus

## Cloud / Async Agents

- **Devin** (Cognition) — vollständig autonom
- **Jules** (Google) — Hintergrund-Tasks, GitHub-Integration
- **GitHub Copilot Workspace** — issue → PR
- **SWE-agent** — Forschung, SWE-Bench

## Skills

**Skills** — Wissen on demand

Wie Neo, der in Sekunden Kung-Fu lernt:
Agenten bekommen Fähigkeiten *injiziert* —
nicht durch Training, sondern durch Kontext.

# Was sind Skills?

## Was sind Skills?

- Wiederverwendbare Prompt-Bausteine / Anweisungen
- Domänenwissen, Patterns, Coding-Standards
- Tool-Nutzungsanleitungen für den Agenten
- In Claude Code: `/skill`-Dateien im Projekt

## Warum wichtig?

- Agent kennt *deine* Konventionen, nicht nur allgemeines Wissen
- Qualität steigt ohne den Agenten neu zu trainieren
- Skills = das neue Institutional Knowledge

# Model Context Protocol

## Was ist MCP?

Ein offenes Protokoll, das Agenten standardisiert
mit externen Tools, Daten und Diensten verbindet.

*„USB-C für KI-Agenten“*

**Das Problem davor:**

- Jede App × jedes Modell = eigene Integration
- N×M Custom-Connectoren, kaum wiederverwendbar

## Die drei Kern-Primitive:

🔧 **Tools** — Aktionen, die der Agent ausführen kann
z.B. Datei lesen, API aufrufen, DB abfragen

📄 **Resources** — Daten, die der Agent lesen kann
z.B. Dateisystem, Dokumentation, Codebase

💬 **Prompts** — Wiederverwendbare Prompt-Templates
z.B. vordefinierte Workflows, Kontext-Snippets

- Anthropic, Nov 2024

**Heute:**
OpenAI, Google, alle großen Anbieter unterstützen MCP.
Seit Dez 2025 unter der Linux Foundation (AAIF).

**Architektur:**

```
Agent (MCP Client)
  ↔ MCP Server A  (GitHub, Jira, …)
  ↔ MCP Server B  (Dateisystem, DB, …)
  ↔ MCP Server C  (eigene Tools, …)
```

## 💡 KI-Transformation

*„Unternehmen, die beim Einführen von KI ihre Prozesse konsequent neu gestalten, übertreffen ihre Umsatzziele doppelt so häufig wie jene, die einfach Tools einführen und auf Wirkung hoffen.“*

**Gartner, 2025**

# Appendix

# 🦤 Der Pelikan-Benchmark

**Was wird gemessen?**

Simon Willison bittet jedes Modell, per Prompt ein SVG zu erzeugen:

*„Generate an SVG of a pelican riding a bicycle.“*

**Warum das interessant ist:**

- Kein Trainingsdatensatz enthält viele Pelikan-auf-Fahrrad-SVGs
- Räumliches Denken + Code-Generierung kombiniert

**Was es misst:**

- Räumliches & physikalisches Verständnis
- Fähigkeit, *ausführbaren* Code zu erzeugen
- Kreativität vs. mechanische Korrektheit
- Fortschritt über Modellgenerationen hinweg

**Ursprung:**
Simon Willison, 2024 —

- Fahrrad korrekt zu zeichnen ist überraschend schwer
- Ergebnis sofort visuell verständlich — kein Rubric nötig

„*I started it as a joke,*
*but it's actually starting to be a bit useful.*“

github.com/simonw/pelican-bicycle

## o1 Pro (High)

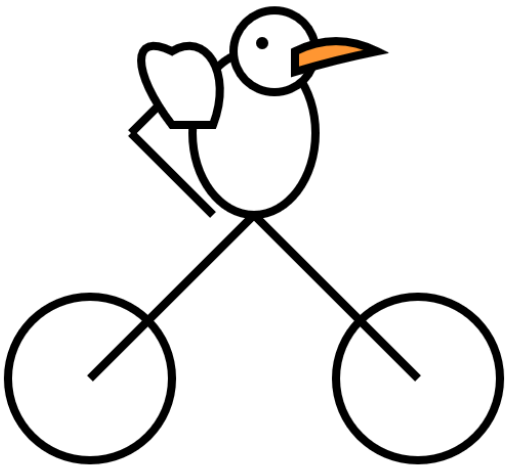

# Deep Think

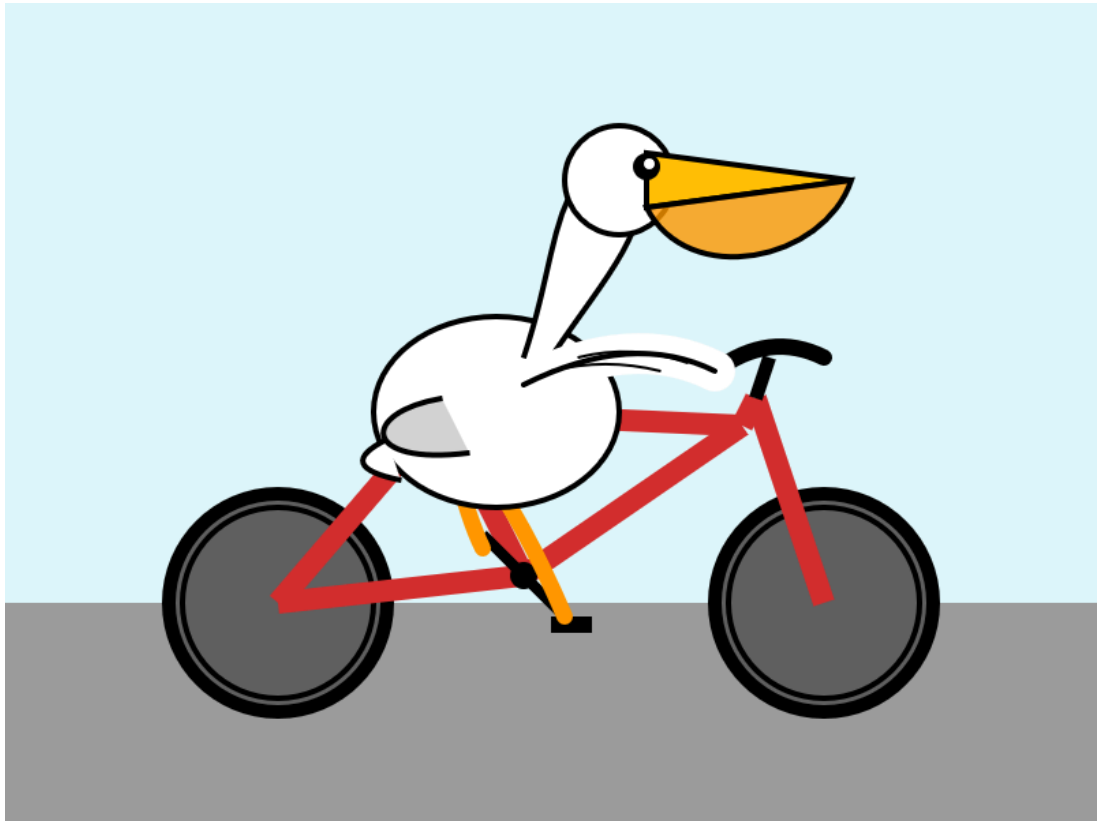

# Gemini Flash Thinking

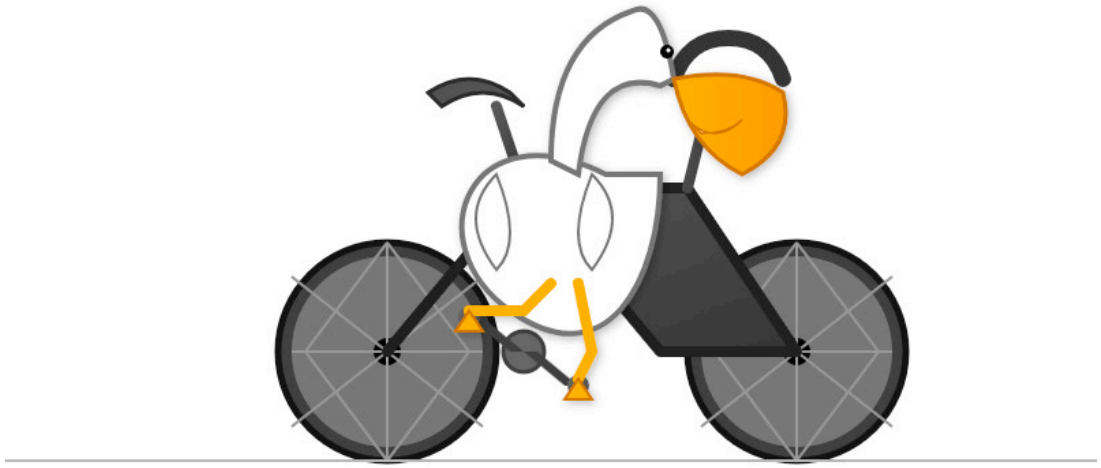

## Gemma 3

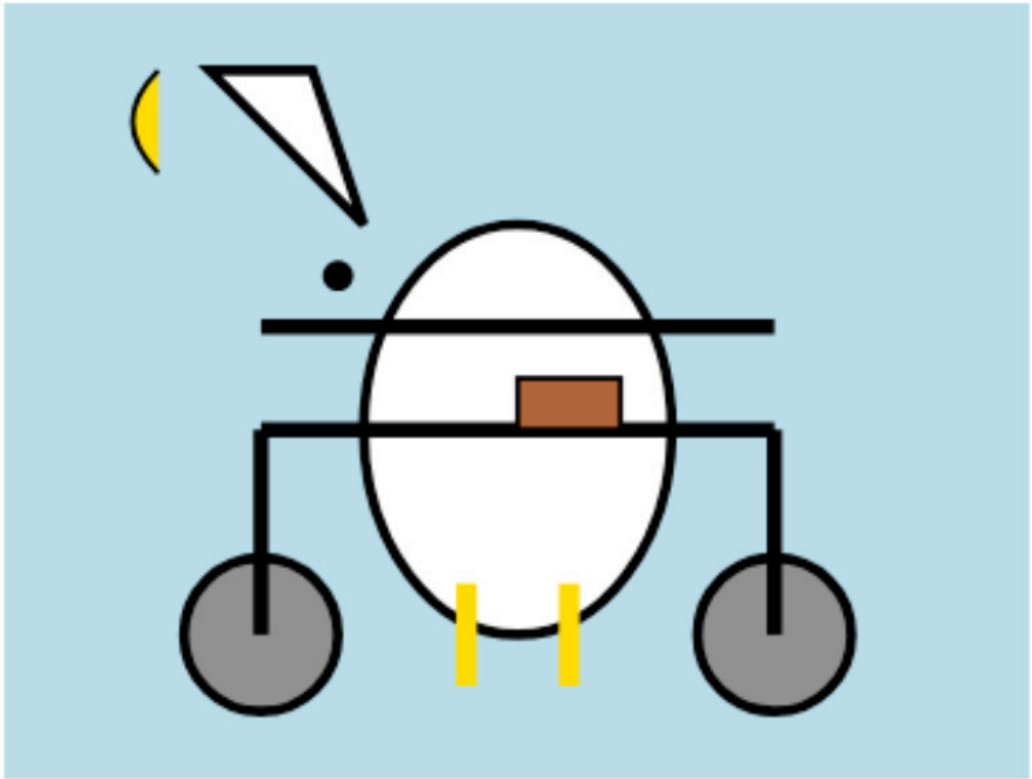

## GPT-4.1

## Gemini (latest)

## Gemini 2.5 Flash Thinking Max

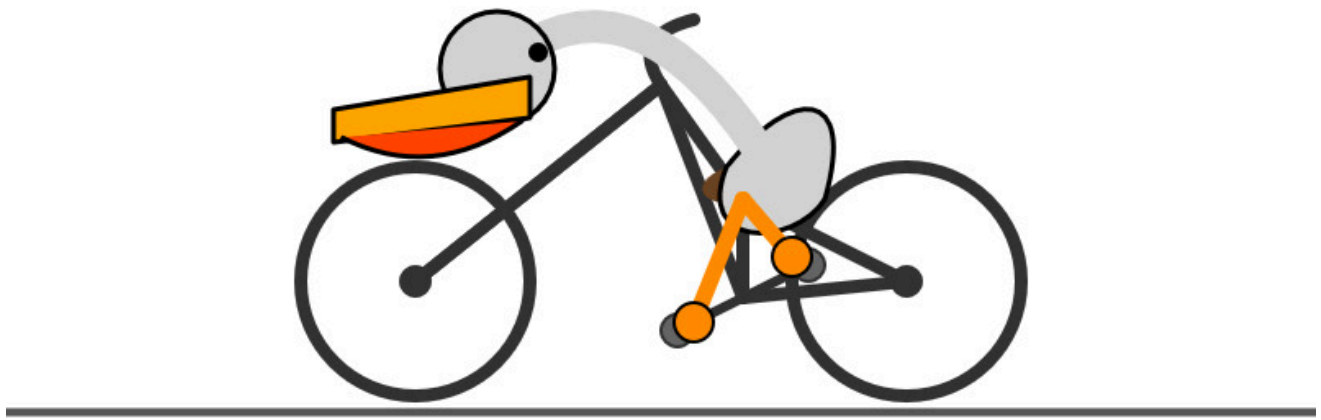

## GLM-4.5

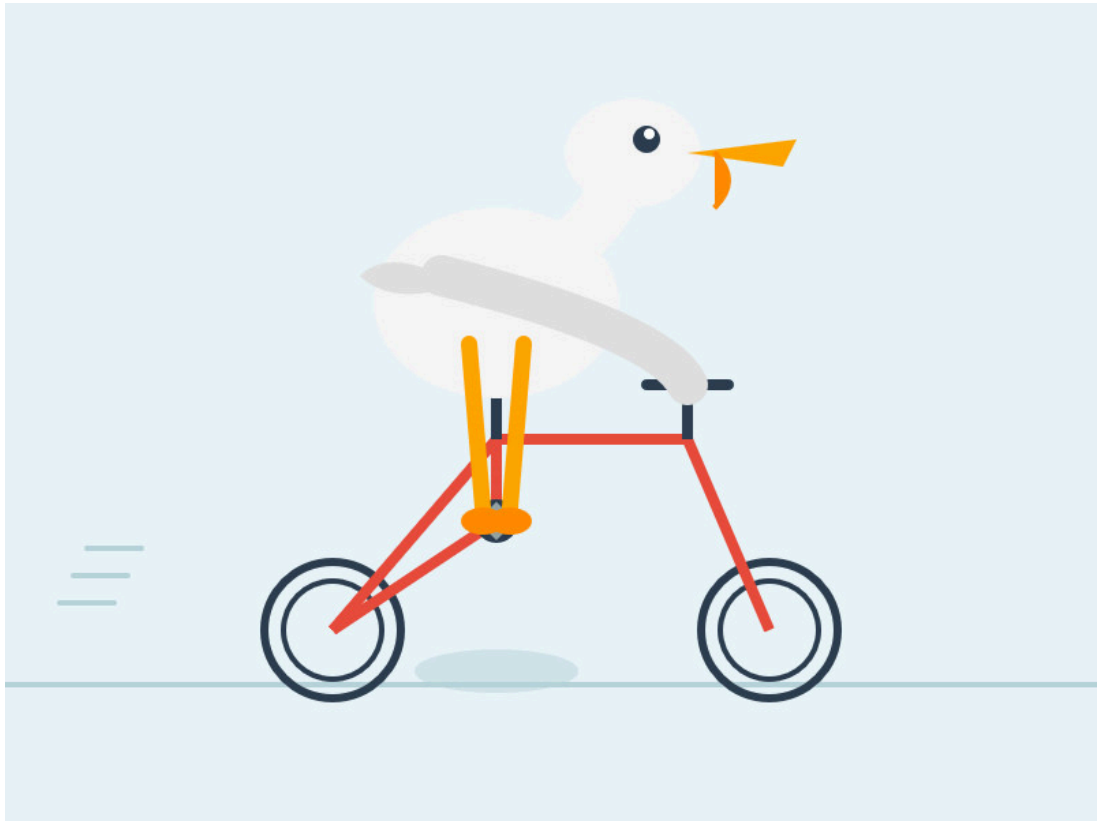

## Kimi K2

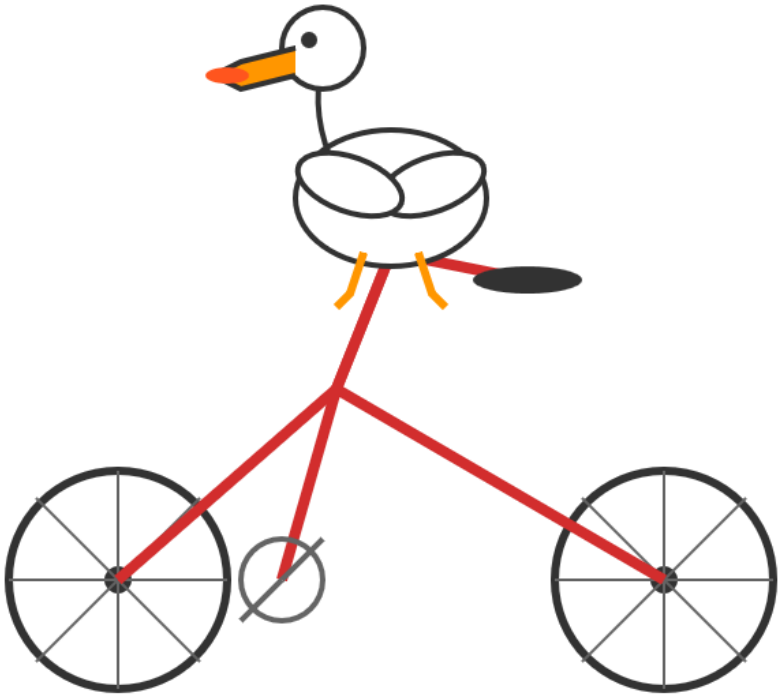

## GPT-5

# GPT-5 Codex API

## GPT-5 Pro

## Claude Opus 4.1

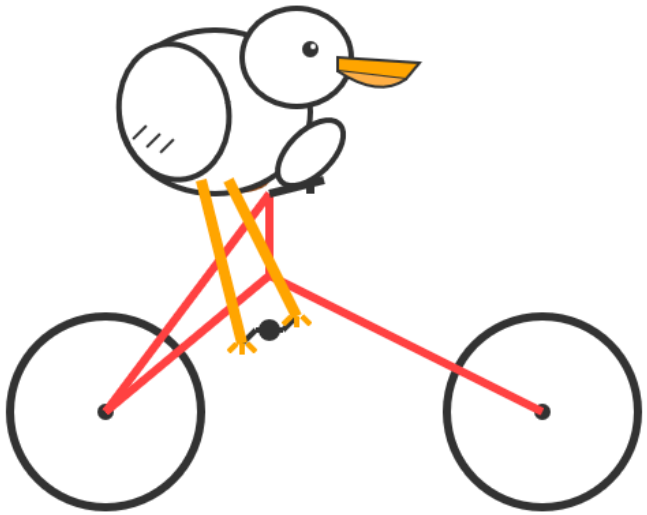

## GPT-5.1 High

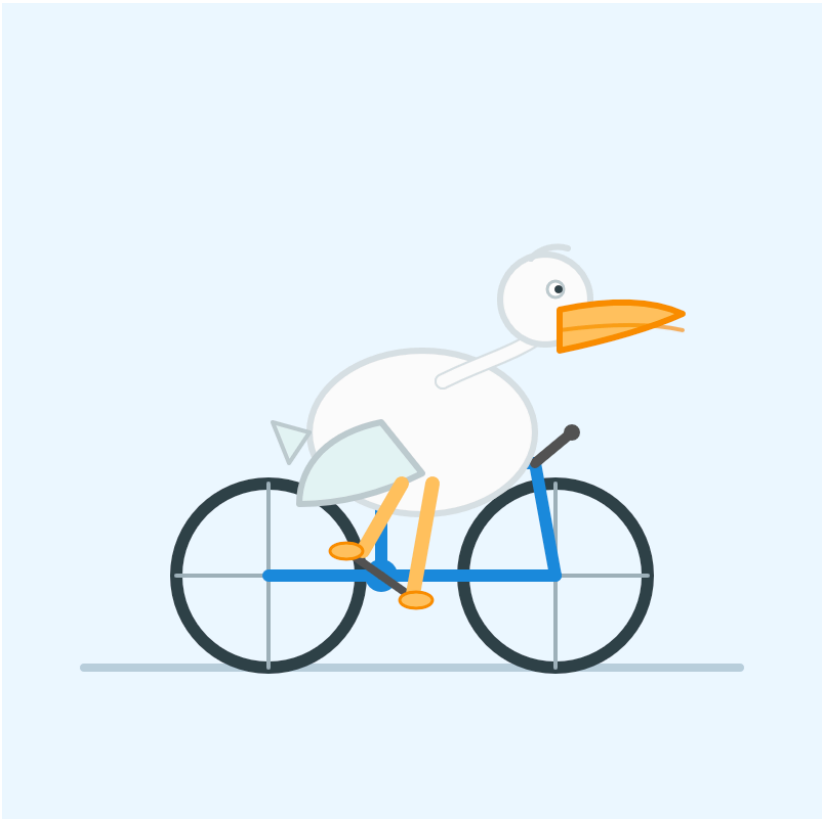

## Claude Opus 4.6

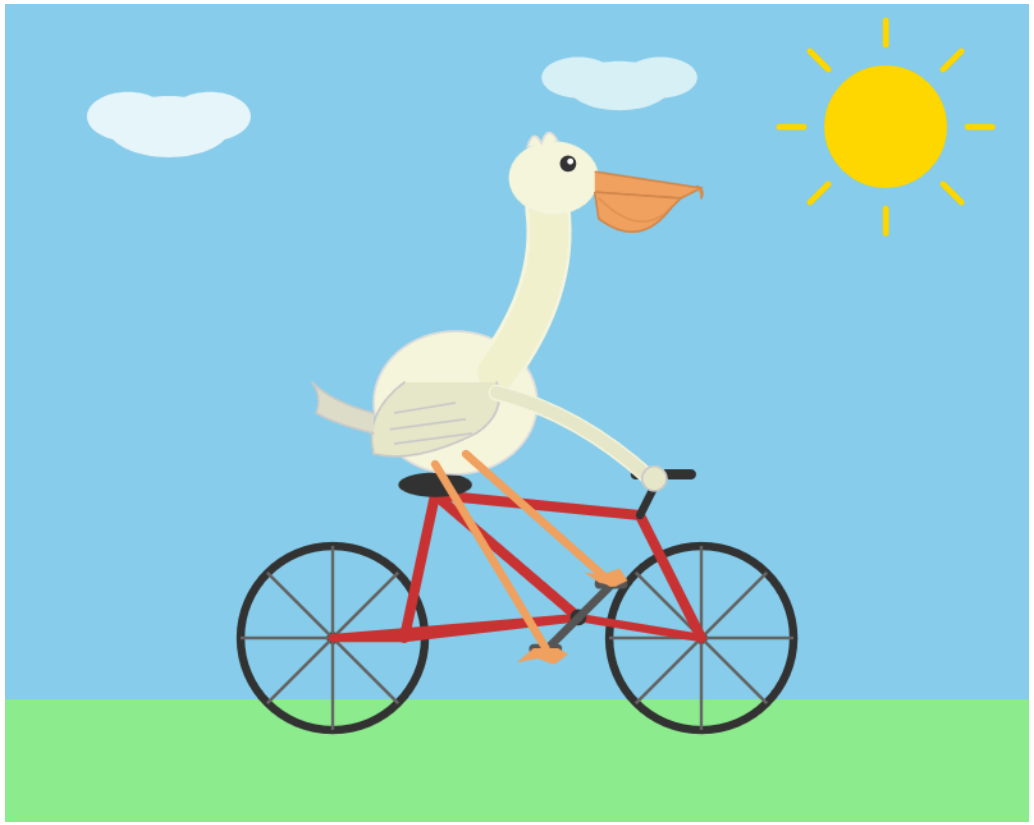

# Gemini 3 Deep Think

## Gemini 3.1 Pro

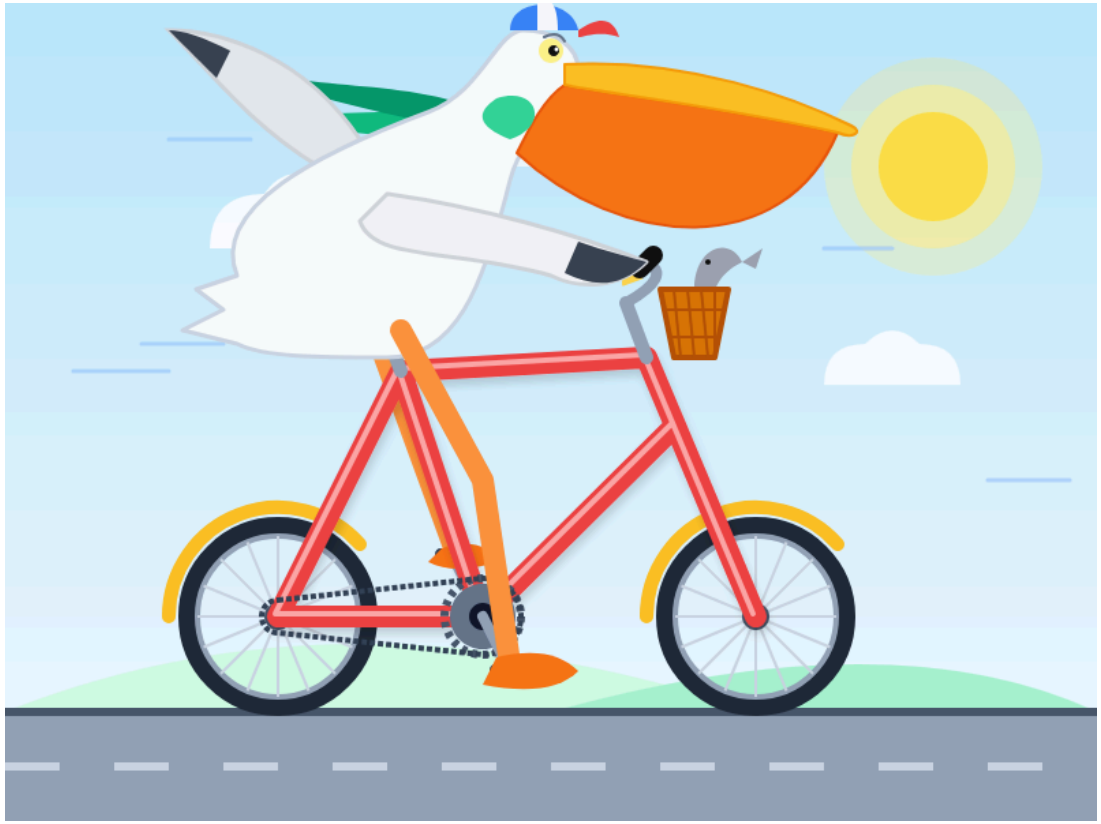

## Quellen & Credits

Pelikan-Bilder und inhaltliche Grundgedanken (Agentic Engineering, Vibe Coding, Pelikan-Benchmark) entnommen aus:

simonwillison.net

Simon Willison's Weblog